

# K-means 聚类及其变分表达、熵正则与空间正则

2025 年 6 月 16 日

## 目录

<b>1</b>	<b>分类的表达</b>	<b>2</b>
<b>2</b>	<b>K-means 算法及其变分表达</b>	<b>3</b>
2.1	K-means 算法 . . . . .	3
2.2	能量不增证明 . . . . .	4
2.3	简要记号与内积 . . . . .	5
<b>3</b>	<b>熵正则化 (Entropy-regularized) K-means</b>	<b>5</b>
3.1	熵正则与光滑化 . . . . .	5
3.1.1	熵的凸性与不等式 . . . . .	5
3.1.2	交替迭代求解 . . . . .	6
<b>4</b>	<b>空间正则化 (Spatial Regularization)</b>	<b>7</b>
4.1	模型的构造 . . . . .	7
4.1.1	卷积形式 (邻域核函数) . . . . .	7
4.1.2	空间正则化 K-means 的变分问题 . . . . .	7
4.2	求解模型: DC 算法 (Difference of Convex) . . . . .	8
4.2.1	DC 基本思路与证明 . . . . .	8
4.2.2	空间正则 K-means 的 DC 形式 . . . . .	9
<b>5</b>	<b>TV 空间正则 (补充)</b>	<b>9</b>
5.1	TV 正则的对偶表示 . . . . .	10
<b>6</b>	<b>内容总结</b>	<b>10</b>

# 期末考纲

在本讲义中，重点围绕以下内容进行整理，并配合完整的推导和证明过程：

## 1. K-means 聚类

- 优化问题
- 主要迭代步骤
- 能量不增证明

## 2. 熵正则 K-means

## 3. 空间正则

- 两个常用的正则项能量式
- 空间正则 K-means 聚类 (优化问题，迭代步骤)

## 4. (补充) TV 空间正则的思路与简要求解。

# 1 分类的表达

给定一个样本  $f$ ，将其划分为  $K$  个类  $\Omega_1, \Omega_2, \Omega_3, \dots, \Omega_K$ ，其类中心分别记为

$$c_1, c_2, \dots, c_K,$$

并要求

$$\Omega_i \cap \Omega_j = \emptyset, \quad \bigcup_{k=1}^K \Omega_k = \Omega.$$

目标是将  $f$  分配给离  $c_k$  最近的类，亦即“就近”原则。

为表示第  $k$  类的示性函数，常用  $\mathbb{R}^K$  的标准正交基

$$\mathbf{e} = (\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_K) = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \dots \begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}.$$

我们定义

$$u_k^* = \begin{cases} 1, & \text{若 } f \in \Omega_k, \\ 0, & \text{else,} \end{cases} \quad \text{并令 } \mathbf{u}^* = (u_1^*, u_2^*, \dots, u_K^*)^T.$$

这样，如果  $f \in \Omega_k$ ，则  $\mathbf{u}^*$  是第  $k$  个标准基向量 (也称 one-hot 向量)。若用  $|f - c_k|^2$  代表“ $f$  与类中心  $c_k$  的相似度的负数” (即用距离平方衡量差异)，则可得到如下变分形式来确定  $\mathbf{u}^*$ :

**Theorem 1.1** (Theorem 1.1). 给定  $f$  以及  $c_1, c_2, \dots, c_K$ . 假设  $\min\{(f-c_1)^2, (f-c_2)^2, \dots, (f-c_K)^2\}$  在某一点严格唯一取得。定义

$$\mathbf{u}^* = \arg \min_{\mathbf{u} \in \mathbb{U}} \sum_{k=1}^K u_k (f - c_k)^2,$$

其中  $\mathbb{U} = \left\{ \mathbf{u} = (u_1, \dots, u_K) : \sum_{k=1}^K u_k = 1, 0 \leq u_k \leq 1 \right\}$ . 则其解为

$$u_k^* = \begin{cases} 1, & k = \arg \min_{k'} \{(f - c_{k'})^2\}, \\ 0, & \text{else.} \end{cases}$$

证明. 设  $m = \min_{k=1, \dots, K} \{(f - c_k)^2\}$ . 容易看到, 对于任何  $\mathbf{u} \in \mathbb{U}$ ,

$$\sum_{k=1}^K u_k (f - c_k)^2 \geq \sum_{k=1}^K u_k \cdot m = m \sum_{k=1}^K u_k = m.$$

当取本定理给出的  $\mathbf{u}^*$ , 则  $\sum_{k=1}^K u_k^* (f - c_k)^2 = m$ . 故此时  $\mathbf{u}^*$  达到最小值。再利用  $m$  的唯一性可知解也唯一。如果  $\min\{\dots\}$  处有多个点, 则  $\mathbf{u}^*$  只不过是多解中的任意一个极小元。□

若把此问题从一维推广到二维, 即在平面上给定样本  $f : \Omega \rightarrow \mathbb{R}$ , 分类问题一样成立, 只需改写为

$$\min_{\mathbf{u} \in \mathbb{U}} \sum_{x \in \Omega} \sum_{k=1}^K u_k(x) (f(x) - c_k)^2,$$

并可得  $\mathbf{u}^*(x)$  的解形同 Theorem 1.1 的结论。这样我们便将分类问题归结为一个变分问题:

$$\min_{\mathbf{u} \in \mathbb{U}, \mathbf{c}} \mathcal{E}(\mathbf{u}, \mathbf{c}) = \sum_{x \in \Omega} \sum_{k=1}^K u_k(x) [f(x) - c_k]^2.$$

它也就是 K-means 聚类算法的变分表达。

## 2 K-means 算法及其变分表达

### 2.1 K-means 算法

我们考虑

$$\min_{\mathbf{u}, \mathbf{c}} \mathcal{E}(\mathbf{u}, \mathbf{c}) = \sum_{x \in \Omega} \sum_{k=1}^K u_k(x) [f(x) - c_k]^2,$$

其中  $\mathbf{u}(x) \in [0, 1]^K$  并满足  $\sum_{k=1}^K u_k(x) = 1$ . K-means 算法是通过在  $\mathbf{u}$  与  $\mathbf{c}$  上交替极小来实现的:

$$\begin{cases} \mathbf{u}^{t+1} = \arg \min_{\mathbf{u} \in \mathbb{U}} \mathcal{E}(\mathbf{u}, \mathbf{c}^t), \\ \mathbf{c}^{t+1} = \arg \min_{\mathbf{c}} \mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c}). \end{cases}$$

(1) **更新  $\mathbf{u}$  子问题** 由 Theorem 1.1 的思路可知, 对于每个  $x$ ,

$$u_k^{t+1}(x) = \begin{cases} 1, & k = \arg \min_{k'} \{ (f(x) - c_{k'}^t)^2 \}, \\ 0, & \text{else.} \end{cases} \quad (1)$$

(2) **更新  $\mathbf{c}$  子问题** 由于  $\mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c})$  关于  $c_k$  呈严格凸, 令其一阶导数为 0, 得到

$$c_k^{t+1} = \frac{\sum_{x \in \Omega} u_k^{t+1}(x) f(x)}{\sum_{x \in \Omega} u_k^{t+1}(x)}. \quad (2)$$

**算法总结** (K-means 聚类):

1. **初始化**: 任意猜测类中心  $\mathbf{c}^0$ .
2. **迭代** (for  $t = 0, 1, 2, \dots$ ):
  - (a) 根据 (1) 式, 更新示性函数  $\mathbf{u}^{t+1}$ .
  - (b) 根据 (2) 式, 更新类中心  $\mathbf{c}^{t+1}$ .
  - (c) 若达到终止条件, 结束; 否则继续。

## 2.2 能量不增证明

**Property 2.1** (K-means 能量单调不增). 由 *K-means* 更新产生的序列  $\{\mathbf{u}^t, \mathbf{c}^t\}$  满足

$$\mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c}^{t+1}) \leq \mathcal{E}(\mathbf{u}^t, \mathbf{c}^t).$$

证明. 第一步:

$$\mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c}^t) \leq \mathcal{E}(\mathbf{u}^t, \mathbf{c}^t),$$

是由  $\mathbf{u}^{t+1}$  相对  $\mathbf{u}$  的最优性得到的。第二步:

$$\mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c}^{t+1}) \leq \mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c}^t),$$

由  $\mathbf{c}^{t+1}$  相对  $\mathbf{c}$  的最优性得到。两者结合即得

$$\mathcal{E}(\mathbf{u}^{t+1}, \mathbf{c}^{t+1}) \leq \mathcal{E}(\mathbf{u}^t, \mathbf{c}^t).$$

又因  $\mathcal{E} \geq 0$ , 故能量序列必有极限值。若  $\mathbf{u}, \mathbf{c}$  的定义域是紧集, 还可进一步证其收敛到某个临界点 (不保证全局最优)。  $\square$

## 2.3 简要记号与内积

为方便起见, 常令

$$O_k(x) = [f(x) - c_k]^2, \quad \mathbf{O}(x) = (O_1(x), \dots, O_K(x)).$$

定义内积

$$\langle \mathbf{O}, \mathbf{u} \rangle = \sum_{x \in \Omega} \sum_{k=1}^K O_k(x) u_k(x).$$

于是 K-means 原问题便写成  $\min_{\mathbf{u}, \mathbf{c}} \langle \mathbf{O}, \mathbf{u} \rangle$ .

## 3 熵正则化 (Entropy-regularized) K-means

### 3.1 熵正则与光滑化

当要对 K-means 做数值优化时, 我们往往需要可微性更好的“软”分类, 而不再是 0/1 示性函数。为此, 我们可以在目标中添加一个熵正则项  $\varepsilon \langle \mathbf{u}, \ln \mathbf{u} \rangle$ . 考虑

$$\min_{\mathbf{u} \in \mathbb{U}, \mathbf{c}} \left\{ \mathcal{E}(\mathbf{u}, \mathbf{c}) + \varepsilon \langle \mathbf{u}, \ln \mathbf{u} \rangle \right\},$$

其中  $\varepsilon > 0$  较小时可以看作对 K-means 的“小扰动”。记  $\varepsilon \langle \mathbf{u}, \ln \mathbf{u} \rangle = -\varepsilon \mathcal{H}(\mathbf{u})$ , 其中  $\mathcal{H}$  表示熵 (neg-entropy)。

#### 3.1.1 熵的凸性与不等式

**Property 3.1.** 设  $\mathbf{u} = (u_k)$  满足  $\sum_{k=1}^K u_k = 1$ ,  $0 \leq u_k \leq 1$ . 则

$$\ln K \geq -\langle \mathbf{u}, \ln \mathbf{u} \rangle \geq -\sum_{k=1}^K u_k \ln u_k \geq 0.$$

左边等号当且仅当  $u_k = \frac{1}{K}$ . 并且用约定  $0 \ln 0 = 0$ .

证明. 令  $f(u) = -\ln u$ . 则  $f''(u) = \frac{1}{u^2} > 0$ , 故  $f$  为凸函数。当  $\sum_k \alpha_k = 1$ ,  $\alpha_k \geq 0$  时,

$$f\left(\sum_k \alpha_k x_k\right) \leq \sum_k \alpha_k f(x_k).$$

选  $\alpha_k = u_k$ ,  $x_k = \frac{1}{u_k}$ . 则

$$-\ln\left(\sum_k u_k \cdot \frac{1}{u_k}\right) = -\ln K \leq \sum_k u_k \ln u_k.$$

取两边加负号便得

$$\ln K \geq -\sum_k u_k \ln u_k.$$

另一方面, 由于  $0 \leq u_k \leq 1$ , 显然  $\sum_k u_k \ln u_k \leq 0$ . 故证毕。  $\square$

### 3.1.2 交替迭代求解

仿照前面的交替框架:

$$\begin{cases} \mathbf{u}^{t+1} = \arg \min_{\mathbf{u} \in \mathbb{U}} \left\{ \langle \mathbf{O}, \mathbf{u} \rangle - \varepsilon \mathcal{H}(\mathbf{u}) \right\}, \\ \mathbf{c}^{t+1} = \arg \min_{\mathbf{c}} \left\{ \langle \mathbf{O}, \mathbf{u}^{t+1} \rangle \right\}. \end{cases}$$

记  $\mathbf{O}$  关于  $\mathbf{c}$  的更新同 K-means, 一阶取零即可得 (2) 式:

$$c_k^{t+1} = \frac{\sum_x u_k^{t+1}(x) f(x)}{\sum_x u_k^{t+1}(x)}.$$

关键在于如何解  $\mathbf{u}$  子问题. 我们写出拉格朗日形式 (注意约束  $\sum_k u_k(x) = 1$ ):

$$\mathcal{L}(\mathbf{u}, \boldsymbol{\lambda}) = \langle \mathbf{O}, \mathbf{u} \rangle - \varepsilon \langle \mathbf{u}, \ln \mathbf{u} \rangle + \sum_{x \in \Omega} \lambda(x) \left( \sum_k u_k(x) - 1 \right).$$

对  $u_k(x)$  做变分分析, 令其一阶导数为 0, 可得

$$O_k(x) + \varepsilon (\ln u_k(x) + 1) + \lambda(x) = 0,$$

进而

$$\ln u_k(x) = \frac{-O_k(x) - \lambda(x)}{\varepsilon} - 1, \implies u_k(x) = \exp \left[ \frac{-O_k(x) - \lambda(x)}{\varepsilon} - 1 \right].$$

因为  $\sum_{k=1}^K u_k(x) = 1$ , 将上式对  $k$  求和得到

$$1 = \sum_k \exp \left[ \frac{-O_k(x) - \lambda(x)}{\varepsilon} - 1 \right] = \exp \left[ \frac{-\lambda(x)}{\varepsilon} - 1 \right] \sum_k \exp \left[ \frac{-O_k(x)}{\varepsilon} \right].$$

$\therefore$

$$\exp \left[ \frac{-\lambda(x)}{\varepsilon} - 1 \right] = \frac{1}{\sum_k \exp \left( \frac{-O_k(x)}{\varepsilon} \right)},$$

于是

$$u_k(x) = \frac{\exp \left[ \frac{-O_k(x)}{\varepsilon} \right]}{\sum_{k'=1}^K \exp \left[ \frac{-O_{k'}(x)}{\varepsilon} \right]} = \text{Softmin}_{\varepsilon}(\mathbf{O}(x))_k.$$

这即对应于 Softmax 的变体. 且当  $\varepsilon \rightarrow 0^+$ , 则  $\mathbf{u}^{t+1}(x)$  会退化成 K-means 中的 0/1 分类. 小结:  $\varepsilon$  越大, 表示对 “二值约束” 松弛程度越强,  $\mathbf{u}$  越 “软”;  $\varepsilon$  越小,  $\mathbf{u}$  越贴近 0/1, 逐渐逼近硬分类.

**Remark 3.2.** 在计算机中实现时, 为避免  $\exp(\text{大数})$  溢出, 也常采用

$$\text{Softmax}(\mathbf{O}) = \frac{\exp(O_k - M)}{\sum \exp(O_k - M)}, \quad \text{其中 } M = \max\{O_1, \dots, O_K\}.$$

## 4 空间正则化 (Spatial Regularization)

### 4.1 模型的构造

K-means 及上述 Softmin/max 主要依赖“点与点的差异”，即  $\mathbf{O}(x)$  中每个分量都只跟  $f(x)$  及  $c_k$  有关，而 **没有**考虑到图像/数据邻域中是否期望“同类”。在真实情形中，常常要求邻域性质：若  $x$  附近的  $N_x$  “看起来”很像  $x$  本身，那么它们应当具有“相同”或“相似”的分类标签。为增强对局部平滑一致性的偏好，可再加一个正则项  $\mathcal{R}(\mathbf{u})$ 。

例如，设  $N_x$  为  $x$  的某个邻域，如果  $\mathbf{u}(x)$  在该邻域里变动太大，就要给出额外的惩罚。最简单的做法是：若  $u_k(x) = 1$ ，则希望  $\forall y \in N_x, u_k(y) = 1$ 。用罚函数来逼迫这一点，可考虑

$$\mathcal{R}(\mathbf{u}) = \sum_x \sum_{k=1}^K u_k(x) \sum_{y \in N_x} [1 - u_k(y)].$$

该和式在“同类”时加 0 (无罚)，在“不同类”时加正值。

#### 4.1.1 卷积形式 (邻域核函数)

当  $N_x$  表示距离  $\|y - x\| < r$  的所有像素集合，可用指示函数  $\mathbf{1}_N(z)$  表示  $N = \{z : \|z\| < r\}$ 。故

$$\mathcal{R}(\mathbf{u}) = \sum_x \sum_{k=1}^K u_k(x) \sum_y \mathbf{1}_N(x - y) [1 - u_k(y)] = \langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle, \mathbf{1}_N(x - y) = \begin{cases} 1, & y \in N \\ 0, & y \in \Omega \setminus N \end{cases}$$

其中  $k(z)$  为核函数 (邻域权)， $k*$  表示卷积。

#### 4.1.2 空间正则化 K-means 的变分问题

综上，我们可得带空间正则项的 K-means 形式 (只写离散型)：

$$\min_{\mathbf{u} \in \mathbb{U}} \langle \mathbf{O}, \mathbf{u} \rangle + \lambda \langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle,$$

若类中心  $\mathbf{c}$  也未知，则完整地写为

$$\min_{\mathbf{u} \in \mathbb{U}, \mathbf{c}} \sum_{k=1}^K \sum_{x \in \Omega} u_k(x) [f(x) - c_k]^2 + \lambda \sum_{k=1}^K \sum_{x \in \Omega} u_k(x) [k * (1 - \mathbf{u})]_k(x).$$

其中  $\lambda \geq 0$  为正则化系数。这样我们在分类时，也兼顾到若干邻域平滑性/一致性。

## 4.2 求解模型：DC 算法 (Difference of Convex)

我们发现  $\mathcal{R}(\mathbf{u}) = \langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle$  里包含了  $\mathbf{u}^T k \mathbf{u}$  这样的二次项，很可能会让问题变得非凸 (或者更复杂)。假如  $k$  是正定核函数，则可证明  $\langle \mathbf{u}, k * \mathbf{u} \rangle$  为正项，从而  $\mathbf{u}^T k \mathbf{u}$  是凸； $\mathcal{R}(\mathbf{u})$  里却是  $\mathbf{u} \cdot (1 - \mathbf{u})$ ，通常被视为凹的一部分。因此可将  $\langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle$  拆分为凸 - 凸的形式。这类问题可用 DC 迭代 (difference of convex) 来做：

### 4.2.1 DC 基本思路与证明

设我们想最小化  $H(x) = f(x) - g(x)$ ，其中  $f$  与  $g$  皆为凸函数。在第  $t$  步时，令

$$\tilde{H}(x) = f(x) - [g(x^t) + g'(x^t)(x - x^t)].$$

其中  $g'(x^t)$  是  $g$  在  $x^t$  处的梯度或次梯度。于是

$$x^{t+1} = \arg \min_x \tilde{H}(x), \quad \tilde{H}(x) = f(x) - [g(x^t) + \langle g'(x^t), x - x^t \rangle].$$

可被看作：

$$x^{t+1} = \arg \min_x \left\{ f(x) + \langle g'(x^t), x \rangle \right\},$$

省略常数项不影响最小点。

**Property 4.1.** 若  $\{x^t\}$  由上式产出，则序列能量不增：

$$H(x^{t+1}) \leq H(x^t) = f(x^t) - g(x^t).$$

证明. 仿照凸分析的思想，对  $g$  做 Taylor 展开 (或者一阶下界)：

$$g(x^{t+1}) \geq g(x^t) + \langle g'(x^t), (x^{t+1} - x^t) \rangle.$$

故

$$\begin{aligned} H(x^{t+1}) - H(x^t) &= [f(x^{t+1}) - f(x^t)] - [g(x^{t+1}) - g(x^t)] \\ &\leq f(x^{t+1}) - f(x^t) - \langle g'(x^t), x^{t+1} - x^t \rangle. \end{aligned}$$

另一方面， $\tilde{H}(x^{t+1}) \leq \tilde{H}(x^t)$  意味着

$$f(x^{t+1}) - \langle g'(x^t), x^{t+1} \rangle \leq f(x^t) - \langle g'(x^t), x^t \rangle,$$

即

$$f(x^{t+1}) - f(x^t) - \langle g'(x^t), (x^{t+1} - x^t) \rangle \leq 0.$$

合并可得  $H(x^{t+1}) \leq H(x^t)$ . 证毕。 □



### 4.2.2 空间正则 K-means 的 DC 形式

回到  $\min_{\mathbf{u}} \langle \mathbf{O}, \mathbf{u} \rangle + \lambda \langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle$ . 我们记

$$\mathcal{F}(\mathbf{u}) = \langle \mathbf{O}, \mathbf{u} \rangle, \quad \mathcal{G}(\mathbf{u}) = -\lambda \langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle,$$

而  $H(\mathbf{u}) = \mathcal{F}(\mathbf{u}) - \mathcal{G}(\mathbf{u})$ . DC 迭代即:

$$\mathbf{u}^{t+1} = \arg \min_{\mathbf{u} \in \mathbb{U}} \left\{ \langle \mathbf{O}, \mathbf{u} \rangle - \left\langle \frac{\delta \mathcal{G}}{\delta \mathbf{u}} \Big|_{\mathbf{u}^t}, \mathbf{u} \right\rangle \right\},$$

即

$$\mathbf{u}^{t+1} = \arg \min_{\mathbf{u} \in \mathbb{U}} \left\{ \left\langle \mathbf{O} - \frac{\delta \mathcal{G}}{\delta \mathbf{u}} \Big|_{\mathbf{u}^t}, \mathbf{u} \right\rangle \right\}.$$

只要  $\mathbf{O} - \frac{\delta \mathcal{G}}{\delta \mathbf{u}}(\mathbf{u}^t)$  可明确表达, 则此时对每个像素  $x$ , 我们在  $K$  个分量中“选最小者为 1, 其它为 0”, 与 K-means 类似。

计算  $\frac{\delta \mathcal{G}}{\delta \mathbf{u}}$  因为  $\mathcal{G} = -\lambda \langle \mathbf{u}, k * (1 - \mathbf{u}) \rangle$ , 故

$$\frac{\delta \mathcal{G}}{\delta u_k} = -\lambda \frac{\delta}{\delta u_k} \left\langle u_k, k * (1 - u_k) \right\rangle.$$

国外文献常做类似推导, 这里省略部分交换积分之类的细节, 结论得到

$$\frac{\delta \mathcal{G}}{\delta u_k} = -\lambda k * [1 - 2u_k].$$

(其中  $k$  常假设对称  $k(z) = k(-z)$ ). 由此, (9) 式的  $\mathbf{u}$ -子问题成为:

$$u_k^{t+1}(x) = \begin{cases} 1, & k = \arg \min_{k'} \left\{ O_{k'}(x) + \lambda [k * (1 - 2u_{k'}^t)](x) \right\}, \\ 0, & \text{else.} \end{cases}$$

类似地, 若要估计中心  $\mathbf{c}$ , 可与 K-means 同理进行 (2) 式更新。

## 5 TV 空间正则 (补充)

另一种常见的空间正则方式是使用全变差 (TV):

$$TV(u) = \int_{\Omega} |\nabla u(\mathbf{x})| d\mathbf{x},$$

它本质上惩罚函数在邻域内过大的梯度变动, 从而鼓励局部分块常值的结构。

## 5.1 TV 正则的对偶表示

常见结论 (如文献中的 Rudin–Osher–Fatemi 模型等):

$$TV(u) = \max_{\mathbf{p} \in \mathbb{P}} \left\{ \int_{\Omega} u(\mathbf{x}) \operatorname{div} \mathbf{p}(\mathbf{x}) d\mathbf{x} \right\},$$

其中  $\mathbb{P} = \{\mathbf{p} \in C_0^1(\Omega), \|\mathbf{p}\|_{\infty} \leq 1\}$ . 对向量值  $\mathbf{u}$ , 则

$$TV(\mathbf{u}) = \sum_{k=1}^K TV(u_k) = \max_{(\mathbf{p}_1, \dots, \mathbf{p}_K) \in \mathbb{P}} \left\{ \sum_{k=1}^K \int_{\Omega} u_k(\mathbf{x}) \operatorname{div}(\mathbf{p}_k)(\mathbf{x}) d\mathbf{x} \right\}.$$

由鞍点原理, 可以做类似的  $\mathbf{p}$ -子问题与  $\mathbf{u}$ -子问题的交替,  $\mathbf{p}$ -子问题通常用投影到  $\|\mathbf{p}\| \leq 1$  的梯度下降。最终, 可以得到 TV 正则分类/分割的迭代算法。在此, 我们不再详尽展开 (可参见 ROF 模型等资料)。只需知道: TV 正则与卷积正则一样都强调局部一致性, 但 TV 强调更“分段常数块”的结构, 适合图像分割等任务。

## 6 内容总结

从以下四方面对分类与聚类的变分思想做了系统梳理:

### 1. K-means 聚类.

- 优化问题:

$$\min_{\mathbf{u}, \mathbf{c}} \sum_{x \in \Omega} \sum_{k=1}^K u_k(x) [f(x) - c_k]^2, \quad \mathbf{u}(x) \in \{0, 1\}^K, \quad \sum_{k=1}^K u_k(x) = 1.$$

- 主要迭代步骤: (1) 式 + (2) 式交替。

- 能量不增证明: 见 §2.2.

2. 熵正则 K-means. 在原目标里加入  $\varepsilon \langle \mathbf{u}, \ln \mathbf{u} \rangle$  构成可微的“软化”分类, 迭代公式类似 Softmin/Softmax。并利用拉格朗日方法推导过溢出处理 ( $\exp(\text{大数})$ )。

### 3. 空间正则

- 两个正则项能量式: (1) 卷积 (邻域) 型  $\mathcal{R}(\mathbf{u})$ , (2) TV 型  $\sum |\nabla u_k|$ .

- 空间正则 K-means 聚类:

$$\min_{\mathbf{u}, \mathbf{c}} \sum_{k=1}^K \sum_x u_k(x) [f(x) - c_k]^2 + \lambda \sum_{k=1}^K \sum_x u_k(x) [k * (1 - \mathbf{u})]_k(x).$$

(或把  $\sum |\nabla u_k|$  替换上去)

- (优化问题, 迭代步骤) 通过 DC 算法或者鞍点法做求解。对  $\mathbf{u}$  子问题采用与 K-means 类似的“选最小 index”, 对  $\mathbf{c}$  子问题采用 (2) 式。

### 4. TV 正则

- 全变差  $TV(\mathbf{u})$  关于  $\mathbf{u}$  是凸的。
- 对偶表示法:  $TV(\mathbf{u}) = \max_{\mathbf{p} \in \mathbb{P}} \int \mathbf{u} \operatorname{div} \mathbf{p}$ .
- 具体在分类/分割中根据鞍点原理拆成  $\mathbf{p}$ -子问题和  $\mathbf{u}$ -子问题交替进行。

这些内容为期末考纲中所需掌握的重点公式、推导及算法思路。本讲义自始至终遵照了变分方法 (energy minimization) 的思路, 由最简单的硬分类 (K-means) 逐步引入熵正则 (Softmax) 与空间正则 (邻域一致或 TV), 打通了分类和分割中核心的变分分析路径。